

Documentación de Machine Learning: TechMind.

Este flujo de trabajo de Machine Learning está diseñado específicamente para la clasificación de información técnica en entornos de desarrollo colaborativo y comunidades de aprendizaje. Para garantizar la máxima eficiencia en el proyecto TechMind, se implementó un análisis comparativo entre los modelos de Regresión Logística y Naive Bayes, seleccionando aquel que demostró un rendimiento superior.

El sistema se sustenta en un pipeline robusto que integra técnicas avanzadas de Procesamiento de Lenguaje Natural (NLP). Este proceso automatizado se encarga de la limpieza, normalización y análisis de textos técnicos complejos, permitiendo una categorización precisa y automatizada de cada entrada de información.

1. Visión General

El objetivo de TechMind es automatizar la categorización de contenido técnico (por ejemplo, preguntas de programación, artículos) en categorías predefinidas como Frontend, Backend, Data Science, DevOps/Cloud, Mobile y Programación General.

2. Preparación de Datos

El conjunto de datos (`techmind_dataset_v2.csv`) contiene títulos técnicos y texto del cuerpo. El proceso realiza los siguientes pasos de limpieza:

- **Normalización de texto:** Convierte todo el texto a minúsculas.
- **Eliminación de ruido:** Elimina URLs, etiquetas HTML y caracteres especiales.
- **Preservación de palabras clave:** Términos técnicos específicos (ej. C++, C#, Python, SQL) están protegidos para no ser eliminados o modificados por la función de limpieza.

3. Ingeniería de Características

Utilizamos la vectorización **TF-IDF (Term Frequency-Inverse Document Frequency)** para convertir el texto a formato numérico:

- **Parámetros:** Número máximo de características establecido en 10,000; ignora términos que aparecen en menos de 2 documentos.
- **Stop Words:** Se aplica una lista personalizada de palabras vacías en inglés y español para reducir el ruido.

4. Entrenamiento y Comparación de Modelos

Se evaluaron dos modelos para determinar el clasificador más efectivo:

Modelo	Precisión (Accuracy)	F1 Score
Regresión Logística (Base)	0.7478	0.7481
Naive Bayes (Multinomial)	0.6822	0.6841

5. Optimización y Selección

El modelo de Regresión Logística fue optimizado mediante **GridSearchCV** para identificar los mejores hiperparámetros:

- **Parámetros evaluados:** C: 0.1, 1.0, 10.0, Solver: 'lbfgs', 'saga'.
- **Mejor configuración:** 'C': 1.0, 'solver': 'lbfgs'.

6. Validación

El modelo optimizado demuestra un alto rendimiento en categorías como Mobile y Data Science, con un enfoque equilibrado entre precisión y recall. Se generaron matrices de confusión para visualizar los errores de clasificación entre dominios técnicos similares.